



RAPPORT – PROSJEKT INF161

PREDIKSJON AV SYKEHUSOPPHOLD

Kris-Joakim Buttedal-Fyllingen



RAPPORT – PREDIKSJON AV SYKEHUSOPPHOLD.....	2
Del 1 – DATATILBEREDNING og UTFORSKENDE DATAANALYSE	2
DEMOGRAFISK DATA	2
Fjerning av Ugyldige Aldersverdier	2
Koding av Kategoriske Variabler	3
SYKEHUS DATA (hospital data).....	3
Fjerning av Ugyldige Oppholdslengder	4
FYSIOLOGISK DATA.....	4
Fjerning av Ugyldige Verdier	4
Mapping av Lungefunksjon	4
ALVORLIGHETSGRAD DATA (severity data)	5
Omstrukturering og Eksplosjon av JSON-data	5
Konvertering av Datatyper og Fjerning av Redundante Kolonner	5
Konsistensregler for Kreftrelaterte Kolonner	6
SAMMENSLÅING AV DATASETTENE	6
Håndtering av Mangelfulle Kolonner og Rader.....	7
Fjerning av Sjeldne Oppholdslengder.....	7
Drøfting av Valg om Fjerning av Sjeldne Oppholdslengder	7
Splitting av Datasett til Trenings-, Validerings- og Testsett	8
VISUALISERINGER	8
Boksploott	9
Korrelasjon	10
Del 2 - MODELLERING og PREDIKSJON.....	13
VARIABELUTVELGELSE (Feature Selection).....	13
IMPUTERING	14
VARIABELUTVINNING (Feature Extraction).....	14
MODELLERING	15
Dummy Modell	16
Decision Tree Regressor	17
Modellbeskrivelse	17
Forventninger til ytelse	17
Hyperparametere	18
Resultater og Evaluering.....	18
Lasso	19
Modellbeskrivelse	19
Forventninger til ytelse	20
Hyperparametere	20
Resultater og Evaluering.....	21
Gradient Boosting Regressor	22
Modellbeskrivelse	22
Forventninger til ytelse	23
Hyperparametere	23
Resultater og Evaluering.....	24
Endelig modell.....	25
De Mest Sentrale Variablene	25
Test - RMSE	27
Modellens Prediksjonsevne: Styrker og Begrensninger	27
Drøfting av Andre Modelltilnærminger	28

RAPPORT – Prediksjon av Sykehusopphold

Denne rapporten beskriver utviklingen av en maskinlæringsmodell for å forutsi den forventede lengden på sykehusoppholdet for pasienter. Modellen bygger på pasientdata som omfatter fysiologiske målinger, demografiske opplysninger og alvorlighetsgraden av sykdommen på tvers av ni forskjellige sykdomskategorier. Hensikten er å gi en estimering av oppholdets varighet basert på disse variablene.

Del 1 – DATATILBEREDNING og UTFORSKENDE DATAANALYSE

Denne delen omhandler forberedelsen av rådataene, som inneholdt fire datasett med pasientinformasjon. Målet er her var å ende opp med en samlet dataframe som kunne brukes videre i modelleringsfasen. Prosessen inkluderer:

- **Databeskrivelse:** En oversikt over datastruktur og innhold.
- **Dataanalyse og visualisering:** Analyse og visualisering for å forstå dataens egenskaper.
- **Datatilberedning:** Rensing og omforming av dataene til en modellklar dataframe.

Som en del av datatilberedningen fjernes duplikater basert på *pasient_id* i alle datasett. Dette er avgjørende for å sikre at hver pasient kun er representert én gang, noe som forhindrer redundans og overrepresentasjon. Denne tilnærmingen bidrar til å etablere en mer robust og pålitelig modell, som baserer seg på unike pasientobservasjoner. Alle valg og metoder vil bli dokumentert og begrunnet.

I tillegg lastes også sampledata inn, som skal brukes for prediksjon når modellen er ferdigtrent. Sampledataene krever ikke omfattende rengjøring, men for å kunne forutsi oppholdslengde med modellen, må disse dataene ha nøyaktig samme variabler og datatyper som treningsdataene. Enkelte tilpasninger på sampledataene er derfor være nødvendige for å sikre at datastrukturen samsvarer med modellens opprinnelige treningsgrunnlag.

DEMOGRAFISK DATA

Demografiske data omfatter variabler som alder, kjønn, utdanning, inntekt og etnisitet. Disse variablene gir innsikt i pasientenes sosiale og økonomiske kontekst, noe som kan ha direkte eller indirekte betydning for oppholdslengde.

Fjerning av Ugyldige Aldersverdier

Ved gjennomgang av alderskolonnen ble det identifisert enkelte negative verdier, som ikke er gyldige for en variabel som skal representere alder. For å opprettholde datakvalitet, ble

alle negative verdier i alder erstattet med NaN. Dette muliggjør senere imputering av de manglende aldersverdiene på en konsistent måte.

Koding av Kategoriske Variabler

Maskinlæringsmodeller krever numeriske variabler, og derfor ble variablene inntekt, kjønn og etnisitet omkodet til numerisk format. Inntektskolonnen består av fire lønnskategorier, samt noen manglende verdier (NaN). For å forenkle analysen ble lønnskategoriene omkodet til numeriske verdier, der 0 representerer laveste inntektsnivå og 4 representerer høyeste inntektsnivå.

Kjønn og etnisitet ble også omgjort til numeriske verdier.

Kolonnene «*kjønn_female*» og «*kjønn_male*» ble vurdert som gjensidig utelukkende, siden en verdi på 0 for «*kjønn_female*» tilsier en verdi på 1 for «*kjønn_male*», og omvendt. For å redusere dimensjonaliteten ble kolonnen «*kjønn_female*» fjernet, og «*kjønn_male*» ble beholdt som representasjon for kjønn.

Etter å ha gjort «*etnisitet*» til dummyvariabler var resultatet fem ulike kolonner som alle beskrev ulik etnisitet. Her ble det gjort et valg om å redusere dimensjonaliteten ved å begrense etnisitetskolonnen til én variabel. Det vil si en binær kolonne der 1 representerer hvit og 0 representerer minoritet. Begrunnelsen for dette valget er som følger:

- **Medisinsk relevans:** Selv om etnisitet kan ha medisinsk betydning, spesielt relatert til genetisk predisposisjon for enkelte sykdommer, er det allerede informasjon om pasientens sykdomshistorikk i andre datasett. Dette gjør den detaljerte etnisitetsinformasjonen mindre nødvendig i denne sammenhengen.
- **Sosioøkonomiske faktorer:** Etnisitet kan være knyttet til sosioøkonomiske forhold, men vi har allerede variabler som utdanning og inntekt som dekker denne dimensjonen.

Formålet med denne tilnærmingen er ikke å utelate etnisitet helt, men snarere å redusere kompleksiteten i datasettet. Flere dimensjoner kan inkludere redundante eller irrelevante data, noe som kan tilføre støy i analysen. Ved å forenkle etnisitetsvariabelen til én kolonne reduseres overflødige detaljer som ikke bidrar særlig til modellen.

SYKEHUS DATA (hospital data)

Sykehusdataene består av variablene «*sykehusdød*» og «*oppholdslengde*». Oppholdslengde er særdeles sentralt, da dette er målvariabelen som skal brukes til å forutsi sykehusoppholdets varighet for nye pasienter.

Fjerning av Ugyldige Oppholdslengder

Minimumsverdien for «*oppholdslengde*» er -99, noe som indikerer en ugyldig verdi for denne variabelen. Ettersom oppholdslengde fungerer som målvariabelen i modellen, fjernes alle rader med ugyldige verdier, i stedet for å sette dem til NaN for senere imputasjon. Å imputere verdier for målvariabelen anses som dårlig praksis, fordi det kan introdusere systematiske feil (bias) som påvirker modellens evne til å generalisere på nye data.

Imputering av målvariabelen kan gi modellen et feilaktig inntrykk av det reelle utfallsområdet og redusere nøyaktigheten, da modellen potensielt vil lære mønstre som ikke finnes i virkeligheten. Ved å fjerne rader med ugyldig oppholdslengde, sikrer man at modellens treningsgrunnlag kun består av realistiske og faktiske verdier, noe som øker påliteligheten i prediksjonene.

FYSIOLOGISK DATA

Fysiologisk data inneholder variabler som er essensielle for vurdering av pasientens vitale funksjoner, og deres avvik fra normale verdier kan være indikatorer på underliggende helseproblemer.

Fjerning av Ugyldige Verdier

Alle kolonnene i de fysiologiske dataene er numeriske. Ved en gjennomgang av minimumsverdiene fremstår flere av disse som 0, noe som i denne sammenhengen betraktes som ugyldige verdier. For eksempel er en verdi på 0 for blodtrykk eller hjertefrekvens ikke meningsfull, da dette indikerer at pasienten allerede er død. Siden 0-verdier i denne konteksten ikke er realistiske, vil disse verdiene bli erstattet med NaN for senere imputasjon.

Mapping av Lungefunksjon

Neste steg var håndtering av kolonnen for lungefunksjon. Verdiene i denne kolonnen deles inn i intervaller basert på PaO₂/FiO₂-forholdet (kilde: <https://litfl.com/pao2-fio2-ratio/>). Disse intervallene representerer ulike grader av alvorlighet og blir deretter konvertert til numeriske verdier gjennom en mapping, der -2 indikerer kritisk tilstand, -1 svært dårlig, 0 moderat, og 1 god. Etter denne omformingen kan den opprinnelige kolonnen for lungefunksjon droppes, da den nå er representert av de nye numeriske verdiene.

Mappingen bidrar til å redusere kompleksiteten i datasettet ved å omdanne kontinuerlige verdier til diskrete kategorier. Dette kan gjøre det lettere for modellen å identifisere mønstre og sammenhenger i dataene. Ved å bruke intervaller for å kategorisere lungefunksjonen, kan man effektivt fange opp variasjoner i pasientens tilstand og tilpasse

modellen til å fokusere på relevante grupperinger, i stedet for å behandle hver enkelt verdi som en unik observasjon.

ALVORLIGHETSGRAD DATA (severity data)

Severity-dataene er opprinnelig lagret i en JSON-fil og krever behandling for å kunne inkluderes i analysen. I denne delen beskrives prosessene for å strukturere dataene hensiktsmessig, inkludert eksplosjon av lister, tilpasning av datatyper og bearbeiding av spesifikke kolonner.

Omstrukturering og Eksplosjon av JSON-data

Severity-dataene ble importert fra JSON-format til en dataframe. Datasettets struktur gjorde det svært vanskelig å arbeide med dataene, ettersom all informasjon var plassert i lister. Målet var å omorganisere dataene slik at hvert element i listene representerte én rad i dataframen.

For å oppnå en tabellstruktur der hver liste forekom som en individuell rad, ble funksjonen «explode()» anvendt. Denne funksjonen transformerte hver liste i de relevante kolonnene til separate rader. Prosessen ble gjennomført i følgende trinn:

- `iloc` ble brukt til å hente kolonner og rader.
- Relevante kolonner ble spesifisert ved hjelp av indeksering for å sikre at eksplosjonen kun påvirket kolonner fra og med den tredje kolonnen, ettersom de to første kolonnene ikke var lister og derfor ikke skulle eksploderes.

Resultatet av `explode()`-prosessen var en dataframe der hvert element i listene representerte en unik rad, noe som gjorde dataene mer tilgjengelige for videre analyser.

Konvertering av Datatyper og Fjerning av Redundante Kolonner

Etter omstruktureringen var alle kolonner i dataframen av typen `object`. For å optimalisere analyser og modellering, var det nødvendig at numeriske verdier fikk en passende numerisk datatype (for eksempel `float`). Derfor ble hver kolonne kontrollert for om den kunne konverteres direkte til numeriske datatyper. Kolonner som inneholdt kategoriske data og ikke kunne konverteres, ble i stedet omgjort til en one-hot encoded representasjon ved hjelp av «`get_dummies`», slik at kategorier ble representert binært.

Etter omstrukturering og datatypekonvertering ble overflødige kolonner som potensielt skapte redundans identifisert:

- Kolonnen «*kreft_no*» ble fjernet, da «*kreft_no*» og «*kreft_yes*» var gjensidig utelukkende.
- Kolonnene med prefikset *sykdomskategori_* ble fjernet ettersom de var overflødige i forhold til kolonnen «*sykdom_underkategori*».

Kolonnene med prefikset *sykdomskategori_* ble fjernet fordi de var redundante i forhold til informasjonen som allerede fantes i kolonnen «*sykdom_underkategori*».

«*sykdom_underkategori*» ga en mer spesifikk klassifisering av pasientenes helsetilstand og tillot en mer detaljert og presis analyse. Ved kun å beholde «*sykdom_underkategori*» ble unødvendig duplisering av data unngått, noe som reduserte datastørrelsen og forbedret lesbarheten og kvaliteten i datasettet.

Konsistensregler for Kreftrelaterte Kolonner

For å sikre datakvalitet og korrekt sammenheng mellom kreftrelaterte kolonner ble kontroller gjennomført basert på følgende regler:

- Dersom «*kreft_metastatic*» var sann, ble «*kreft_yes*» også satt til sann.
- Når «*kreft_yes*» var usann, ble «*kreft_metastatic*» også satt til usann.
- Dersom «*sykdom_underkategori_Colon Cancer*» eller «*sykdom_underkategori_Lung Cancer*» var sann, ble «*kreft_yes*» også satt til sann.
- Når «*kreft_yes*» var usann, ble både «*sykdom_underkategori_Colon Cancer*» og «*sykdom_underkategori_Lung Cancer*» satt til usanne.

Gjennomgangen og korrigeringen av disse kolonneverdiene sikret logisk konsistens, noe som bidro til forbedret datakvalitet. Denne prosessen var avgjørende for å sikre meningsfull analyse ved å gi et sammenhengende bilde av pasientens tilstand. Ved å følge disse reglene, var kolonneverdiene i tråd med logiske forventninger, noe som reduserte risikoen for inkonsistens. En slik struktur var viktig for å unngå feilaktige analyser som kunne påvirke modellens prediksjoner.

SAMMENSLÅING AV DATASETTENE

Etter en individuell gjennomgang av de fire datasettene var neste steg å kombinere dem til en samlet dataframe basert på pasientens unike identifikator, «*pasient_id*». Først ble *demographic_raw_df* og *hospital_raw_df* slått sammen gjennom en ytre join på «*pasient_id*» for å inkludere alle pasienter, uavhengig av om de var til stede i begge datasettene. Deretter ble *physiological_raw_df* lagt til, fortsatt basert på «*pasient_id*», slik at fysiologiske data ble integrert. Til slutt ble *severity_raw_df* inkludert for å fullføre datagrunnlaget.

For å sikre at datasettet ikke inneholdt tomme rader uten pasientidentifikator, ble rader uten «*pasient_id*» fjernet etter sammenslåingen. Resultatet var en enhetlig dataframe som inneholdt all tilgjengelig informasjon om pasientene.

Håndtering av Mangelfulle Kolonner og Rader

I det sammenslåtte datasettet ble kolonnene gjennomgått for manglende verdier.

Kolonnen «*dnr_dag*», som manglet for nesten alle pasienter, ble fjernet på grunn av sin lave informasjonsverdi. Kolonnene «*adl_pasient*» og «*adl_stedfortreder*», som beskriver omtrent samme informasjon, ble kombinert til én kolonne for å forenkle strukturen.

For rader med omfattende mangler ble terskelen satt til å tillate inntil 16 av 32 kolonner med NaN-verdier, noe som betyr at rader med over 50 % NaN-verdier ble fjernet for å opprettholde datakvaliteten.

Fjerning av Sjeldne Oppholdslengder

I tillegg ble rader der oppholdslengden forekommer kun én gang i datasettet fjernet.

Fjerningen av disse sjeldne oppholdslengdene er et strategisk valg for å redusere datastøy og styrke modellens evne til å generalisere på usett data. Ved å eliminere unike, sjeldne verdier, reduseres risikoen for overfitting – altså at modellen tilpasser seg uforholdsmessig til spesielle tilfeller som ikke representerer den generelle pasientpopulasjonen. Dette skaper en mer homogen fordeling av oppholdslengder i datasettet, noe som forbedrer modellens evne til å lære fra de mest representative verdiene. På den måten vil modellen kunne levere mer presise prediksjoner for flertallet av pasientene.

Drøfting av Valg om Fjerning av Sjeldne Oppholdslengder

Fjerning av oppholdslengder som kun forekommer én gang i datasettet har klare fordeler, særlig når målet er å utvikle en modell med god generaliseringsevne. Sjeldne verdier kan ofte representere uvanlige eller ekstreme tilfeller som ikke nødvendigvis gir informasjon om flertallet av pasientpopulasjonen. Når slike tilfeller inkluderes i modellen, kan de fungere som "støy", hvilket innebærer at modellen i større grad tilpasser seg unike avvik fremfor den generelle trenden. Dette kan lede til overfitting, hvor modellen presterer godt på treningsdata, men dårligere på usett data.

Ved å fjerne sjeldne verdier, reduseres risikoen for at modellen fanger opp tilfeldige variasjoner som ikke reflekterer de overordnede mønstrene i datasettet. Dermed kan en mer pålitelig modell utvikles som opprettholder en god balanse mellom nøyaktighet og generalisering, noe som er essensielt for å oppnå robusthet i prediksjoner.

Samtidig medfører fjerningen av sjeldne oppholdslengder en risiko for tap av viktig informasjon som kan være verdifull, spesielt i medisinske analyser der sjeldne tilfeller kan representere spesifikke sykdomsforløp eller pasientkategorier. Slike verdier kan avsløre

uvanlige mønstre eller gi innsikt i medisinske tilstander som ikke er vanlige, men som likevel er viktige for helhetsbildet i en dybdeanalyse eller en spesialisert modell. Dermed kan variert data være fordelaktig for utvikling av presise modeller til bruk i medisinske sammenhenger, som krever en bred forståelse av forskjellige utfall, også de som er mindre vanlige.

Beslutningen om å fjerne sjeldne oppholdslengder innebærer dermed en vurdering mellom å redusere støy og oppnå en mer robust modell, mot å bevare variasjonen i datasettet. For denne modellen, som har som mål å generalisere godt på tvers av en stor pasientgruppe, er det viktig å sikre at den først og fremst lærer fra verdier som er representative for majoriteten. Dette resulterer i en modell som er bedre tilpasset for å levere presise prediksjoner for de fleste pasientene, ettersom den fokuserer på vanlige og hyppigere forekommende oppholdslengder. Det er også viktig å påpeke at det kun fjernes oppholdslengder som forekommer én enkelt gang i datasettet, alle andre oppholdslengder beholdes, så dataen inneholder mer enn nok variasjon til å predikere ulike tilfeller.

Alternativt kan man også argumentere for at dersom man ønsker en modell med spesialiserte egenskaper – for eksempel for en spesifikk pasientgruppe eller medisinsk tilstand – vil det kunne være fordelaktig å beholde sjeldne verdier for å reflektere en bredere variasjon. Dette ville gitt et bredere perspektiv, men med risiko for lavere prediksjonsnøyaktighet på pasientpopulasjonen som helhet.


Splitting av Datasett til Trenings-, Validerings- og Testsett

For videre modellutvikling ble datasettet delt inn i treningsdata (70 %) og et midlertidig datasett (30 %). Dette midlertidige settet ble deretter splittet i to like store deler, hvor 50 % utgjorde valideringsdata og 50 % testdata. Totalt sett ble dataen da delt inn 70% treningsdata, 15% valideringsdata og 15% testdata. Denne strukturen sikrer at modellen kan trenes på et betydelig datagrunnlag, valideres for optimal parameterjustering, og til slutt testes på testdata for å gi en objektiv vurdering av modellens generaliseringsevne.

VISUALISERINGER

Visualiseringsdelen har som mål å gi en helhetlig forståelse av datasettene. Visualiseringene bidrar til å identifisere mønstre, korrelasjoner, og eventuelle skjevheter i dataene. Denne innsikten er viktig for å optimalisere datavalget og velge relevante variabler. Målet er at visualiseringene tydeliggjør datasettets egenskaper.

Boksplott




Figur 1: Boxplottet viser fordelingen av oppholdslengden. Medianen vises som den vertikale linjen i midten av boksen. Boksen strekker seg fra ca. 5 dager (nedre kvartil) til ca. 19 dager (øvre kvartil), som definerer interkvartilområdet (IQR). Whiskers strekker seg fra 3 dager til ca. 41 dager, og representerer verdier innenfor 1,5 ganger IQR. Punkter utenfor whiskers, opp til ca. 165 dager, indikerer outliers eller ekstreme verdier.

Figur 1 indikerer en moderat variasjon i hvor lenge pasientene oppholder seg på sykehuset, med de fleste pasientene som har opphold på maksimalt 40 dager. Denne informasjonen tyder på at de fleste tilfeller av innleggelse ligger innenfor et relativt standardisert tidsrom, noe som kan reflektere vanlig praksis for behandling eller rehabilitering. Imidlertid observeres det også en betydelig spredning av ekstreme verdier utenfor whiskers. Disse outlierne kan indikere pasienter med spesielle medisinske tilstander eller kompliserte sykdomsforløp som krever lengre opphold enn det som er vanlig.

Figur 2: Boksplott for numeriske variabler. Hver boks representerer fordelingen av en numerisk variabel, med medianen vist som en vertikal linje i midten. Boksen strekker seg fra nedre kvartil til øvre kvartil, og whiskers viser verdier innenfor 1,5 ganger IQR. Punkter utenfor whiskers representerer ekstreme verdier eller outliers.


Figur 2 viser et sett med boksplott for de numeriske variablene i datasettet. En tydelig observasjon er den store variasjonen i ekstremverdiene for enkelte variabler. Som i figur 1 indikerer dette tilstedeværelsen av flere outliers, som kan være resultatet av unike fysiologiske tilstander hos pasientene.

Det er imidlertid viktig å merke seg at disse ekstreme verdiene ikke nødvendigvis er ugyldige eller feilaktige. Gitt at det dreier seg om kritisk syke pasienter, kan det være helt legitime fysiologiske variasjoner som reflekterer deres alvorlige helsetilstand. Det er dermed vanskelig å konkludere på dette tidspunkt om



disse verdiene bør fjernes fra analysen. Å ignorere disse potensielt gyldige dataene kan resultere i tap av viktig informasjon som kan være avgjørende for å forstå pasientenes tilstand og dermed også oppholdslengden.

Korrelasjon




Figur 3: Figuren viser et søylediagram som illustrerer korrelasjonen mellom de ulike variablene i datasettet og målvariabelen "oppholdslengde". Diagrammet gir en indikasjon på hvilke parametre som har sterkest lineær sammenheng med oppholdslengden.

Figur 3 gir en verdifull oversikt over hvilke faktorer som kan påvirke lengden av sykehusopphold for pasienter. Den høyeste positive korrelasjonen er observert med variabelen «sykdom_underkategori_ARF/MOSF w/Sepsis», som viser en korrelasjon på rundt 0.31. Dette indikerer at pasienter med akutt respiratorisk svikt eller multiorgansvikt i kombinasjon med sepsis har en tendens til å ha lengre opphold. På den annen side viser variabelen «kreft_metastatic» den sterkeste negative korrelasjonen på rundt -0.17, noe som kan tyde på at pasienter med metastatisk kreft har en svak tendens til kortere sykehusopphold, muligens fordi en del pasienter her er i terminalfase og får palliativ omsorg fremfor aktiv behandling.

Flere variabler har korrelasjoner nær null, som «blodtrykk» og «sykdom_underkategori MOSF w/Malign». Disse midterste korrelasjonene tyder på at det ikke er en signifikant lineær sammenheng mellom disse variablene og oppholdslengden. Men her er det viktig å merke

seg at diagrammet kun fanger opp lineære relasjoner, og at eventuelle ikke-lineære sammenhenger ikke er synlige i denne fremstillingen. Til tross for dette gir figuren en nyttig oversikt over potensielt sentrale variabler som kan påvirke lengden på sykehusopphold.



Figur 4: Figuren viser en korrelasjonsmatrise som visualiserer sammenhengen mellom alle variablene i datasettet. Denne matrisen gir en omfattende oversikt over korrelasjonene både mellom de ulike variablene og hvordan de relaterer seg til hverandre, uavhengig av målvariabelen «oppholdslengde». Ved å inkludere alle variabler gir matrisen innsikt i hvilke variabler som har sterke lineære sammenhenger seg imellom.

Figur 4 presenterer hele korrelasjonsmatrisen, som gir en omfattende oversikt over sammenhengene mellom de ulike variablene i datasettet. Analysen av disse korrelasjonene er avgjørende, da den ikke bare gir innsikt i hvordan hver enkelt variabel forholder seg til målvariabelen, oppholdslengde, men også avdekker potensielle sammenhenger og interaksjoner mellom de uavhengige variablene. Denne informasjonen er essensiell for å forstå de underliggende dynamikkene som påvirker pasientopphold og kan avdekke viktige

relasjoner som ville gått tapt ved å fokusere utelukkende på korrelasjonen med målvariabelen.

Blant de variablene med høy korrelasjon er det særlig bemerkelsesverdig at «*overlevelsesestimater_2mnd*» og «*overlevelsesestimater_6mnd*» har en ekstremt høy korrelasjon. Denne sterke positive sammenhengen antyder at pasienter med et godt overlevelsesestimater etter to måneder sannsynligvis også vil ha et tilsvarende estimater etter seks måneder. Dette indikerer at tidlige vurderinger av pasientens tilstand kan fungere som en god indikator for fremtidige utfall. Tilsvarende korrelasjonstendenser observeres også mellom «*lege_overlevelsesestimater_2mnd*» og «*lege_overlevelsesestimater_6mnd*».

En annen betydelig korrelasjon finnes mellom «*fysiologisk_score*» og «*apache_fysiologisk_score*», noe som tyder på at disse variablene måler lignende aspekter av pasientens fysiologiske tilstand. Videre er det en markant negativ korrelasjon mellom «*fysiologisk_score*» og «*overlevelsesestimater_2mnd*». Dette indikerer at en høyere fysiologisk score, som reflekterer en dårligere helsetilstand, er assosiert med lavere overlevelsesestimater.

Her er det viktig å merke seg problematikken knyttet til høyt korrelerte uavhengige variabler, kjent som multikolinearitet. En av de mest betydelige konsekvensene av multikolinearitet er at det kan påvirke modellens prestasjon negativt.

Når uavhengige variabler er sterkt korrelert, kan dette føre til at modellen får vanskeligheter med å skille mellom effektene av de ulike variablene. Dette kan resultere i unøyaktige prediksjoner og mindre pålitelige estimater av koeffisientene, noe som i sin tur kan svekke modellens evne til å generalisere på nye data. I tillegg kan høy korrelasjon mellom variabler føre til en reduksjon i statistisk signifikans for enkelte uavhengige variabler. Dette kan gi inntrykk av at visse variabler ikke har en betydelig effekt på målvariabelen, selv om de faktisk er relevante. Som et resultat kan viktige forhold og sammenhenger bli oversett, noe som begrenser analysens dybde og anvendbarhet.

For å unngå slike problemer er det viktig å vurdere multikolinearitet og modellprestasjon videre. For å håndtere disse variablene kan man potensielt eliminere eller kombinere sterkt korrelerte variabler.

Del 2 - MODELLERING og PREDIKSJON

Her ble det lagt vekt på utviklingen av en maskinlæringsmodell for å predikere lengden på sykehusoppholdet, basert på den forberedte dataframen. Tre ulike modelleringsmetoder ble evaluert før den endelige modellen ble valgt. Sentrale deler inkluderer valg av variabler og håndtering av manglende data gjennom imputering.

Modellen ble trent på treningsdata, og ytelsen til hver modell ble vurdert i henhold til dens prestasjon på valideringsdata. Modellen med den laveste validerings-RMSE ble valgt som den endelige. Avslutningsvis ble denne modellen testet mot et testdatasett for å gi en objektiv vurdering av dens generaliseringsevne.

VARIABELUTVELGELSE (Feature Selection)

Under variabelutvelgelsen fjernes variabler som ikke har signifikant innvirkning på prediksjonen av oppholdslengde. Enkelte variabler kan være irrelevante eller ha høy grad av multikolinearitet, noe som kan føre til redundans og skjevheter i modellens parametere. Ved å eliminere slike variabler reduseres risikoen for overtilpasning, og modellen kan oppnå bedre generaliseringsevne på nye data.

Ettersom målet er å forutsi oppholdslengde, så blir variabler som «sykehusdød» og «dødsfall» ekskludert, da de ikke kan forutsies ved pasientens innleggelse. Inkludering av «sykehusdød» eller «dødsfall» vil kunne forvrengte modellens vurderinger, da de representerer resultater som kun kan observeres etter at oppholdet har funnet sted.

Videre fjernes «adl_combined» og «dnr_status_dnr før innleggelse», da de ikke er tilgjengelige fra dag 1. ADL-dataene, for eksempel, er delvis samlet på dag 7, mens prediksjonene her skal baseres på informasjon som er tilgjengelig ved innleggelse.

For å unngå multikollinearitet fjernes en av de to variablene som er sterkt korrelert med hverandre. Her elimineres kolonnene «fysiologisk_score», «lege_overlevelsesestimat_6mnd», og «overlevelsesestimat_6mnd».

Variabler med høy korrelasjon:			
	Variable 1	Variable 2	Correlation
0	overlevelsesestimat_2mnd	overlevelsesestimat_6mnd	0.960902
1	lege_overlevelsesestimat_2mnd	lege_overlevelsesestimat_6mnd	0.897645
2	fysiologisk_score	apache_fysiologisk_score	0.803704
3	fysiologisk_score	overlevelsesestimat_2mnd	-0.757183

Figur 5: Viser variabler som er høyt korrelerte.

For å evaluere hvordan disse variablene påvirker modellens ytelse, sammenlignes resultatene både med og uten de aktuelle variablene. Denne sammenligningen gir verdifull innsikt i hvorvidt inkluderingen av disse variablene forbedrer eller svekker modellens prediksjonsskapasitet.

IMPUTERING

Imputering av manglende verdier er en kritisk del av dataforberedelsesprosessen. I funksjonen «`impute_missing_values()`» begynner prosessen med å identifisere kolonner som inneholder manglende verdier. Når kolonnene med manglende verdier er identifisert, velges en passende imputeringsteknikk basert på datatypen i målvariabelen. Merk målvariabelen i denne sammenhengen er ikke oppholdslengde, men den aktuelle kolonnen som skal imputeres. For kontinuerlige målvariabler anvendes en `DecisionTreeRegressor`. I tilfeller der målvariabelen er kategorisk, benyttes en `DecisionTreeClassifier`, som klassifiserer de manglende verdiene basert på tilgjengelige data.

Etter modellvalget trenes modellen ved hjelp av de tilgjengelige dataene i treningssettet. Her blir både de uavhengige variablene og de eksisterende verdiene i målvariabelen brukt, noe som sikrer at modellen får tilstrekkelig informasjon til å lære relevante mønstre. Når modellen er trent, benyttes den til å imputere manglende verdier i både validerings- og testdata. Denne tilnærmingen er spesielt viktig for å opprettholde konsistens og redusere risikoen for datalekkasje, da den kun bruker informasjon fra treningssettet under treningen.

Selv om enklere imputeringsmetoder, som gjennomsnitt, median eller modus, kan virke lett tilgjengelige og enkle å implementere, er det flere grunner til at disse alternativene ofte unngås i mer komplekse datasett. For det første kan slike metoder føre til tap av viktig informasjon. For eksempel, ved å bruke gjennomsnittet for å imputere kontinuerlige verdier, kan man miste variasjonen og skape en skjevhet i dataene.

Videre tar enklere metoder ikke hensyn til relasjonene mellom variablene, noe som kan resultere i unøyaktige imputeringer. Bruken av en beslutningstre-modell gir derimot en mer nyansert tilnærming, som i større grad kan gjenspeile de underliggende strukturene i dataene. Ved å velge en mer sofistikert imputeringsteknikk oppnår man også en potensielt forbedret modellprestasjon. Dette skyldes at de manglende verdiene erstattes med mer informative estimater som er avledet fra de tilgjengelige dataene.

Til slutt er beslutningstre-modeller kjent for sin robusthet, da de kan håndtere utliggere og ikke-lineære forhold mellom variabler, noe som gir mer nøyaktige imputeringer i situasjoner med komplekse data.

VARIABELUTVINNING (Feature Extraction)

Feature extraction, eller variabelutvinning, er en teknikk som brukes for å forbedre datakvaliteten ved å generere nye, informative variabler fra eksisterende data. Denne tilnærmingen kan gi flere fordeler: For det første kan den forbedre modellprestasjonen ved å identifisere og utvikle relevante variabler, noe som øker modellens evne til å generalisere og

gjøre nøyaktige prediksjoner. Videre kan den redusere dimensjonaliteten ved å fjerne unødvendige eller irrelevante variabler, noe som forenkler analysen av datasettet.

Under variabelutvinningen beregnes det to nye variabler: «*lung_score*» og «*heart_score*», som vurderer pasientens helse ved hjelp av relevante fysiologiske variabler. Lungescore er basert på «*respirasjonsfrekvens*» og «*lungefunksjon_kode*», mens hjertescore vurderes gjennom «*blodtrykk*» og «*hjerterfrekvens*». Disse variablene sammenlignes med definerte optimale verdier for å bestemme avvikene fra det normale området. De opprinnelige variablene «*respirasjonsfrekvens*», «*lungefunksjon_kode*», «*blodtrykk*» og «*hjerterfrekvens*» fjernes til fordel for de nye variablene lungescore og hjertescore.

For å kvantifisere alvorlighetsgraden av disse avvikene implementeres en poenggivende funksjon som straffer betydelige forskjeller fra de optimale verdiene. Jo større avvik, desto lavere poengscore oppnås. Denne straffefunksjonen gir en indikasjon på hvordan hvert avvik kan påvirke pasientens helse.

De resulterende scorene normaliseres til et intervall mellom 0 og 1, noe som letter sammenligningen av pasienters helse. Etter normaliseringen kombineres lungescore og hjertescore i vektete indekser, der hver score tillegges en vekt avhengig av dens kliniske betydning. For eksempel vektet blodtrykk med 60% og hjerterfrekvens med 40%, noe som reflekteres i den endelige indeksen.

Det er også essensielt å vurdere effekten av å inkludere eller ekskludere disse variablene i modellen. Dette innebærer at modellene vil bli trent både med og uten disse variablene, noe som gir innsikt i hvordan de påvirker modellprestasjon.

MODELLERING

I denne fasen av prosjektet ble det fokusert på å utvikle og validere prediksjonsmodeller for å estimere lengden på sykehusopphold. Modellene som ble utprøvd var Decision Tree Regressor, Lasso og Gradient Boosting Regressor. Selve modelleringen omfattet flere nøkkeltrinn. For det første ble modellene validert ved å trene dem med treningsdata og evaluere deres ytelse på valideringsdata. Dette ga en indikasjon på hvordan modellene ville prestere på usett data og hjalp til med å unngå overfitting.

For å velge den beste modellen, ble prestasjonen til modellene vurdert basert på validerings-RMSE (Root Mean Squared Error). I dette prosjektet representerte RMSE gjennomsnittlig avvik i oppholdsdager. I tillegg ble modellene trent både med og uten uteliggere i treningsdataen (X_{train}). Uteliggere ble fjernet kun fra treningssettet for å hindre at de forstyrret modellens læringsprosess. Det var viktig å beholde uteliggere i valideringssettet (X_{val}) for å kunne evaluere hvordan modellene håndterte slike observasjoner i virkelige situasjoner.

Videre ble modellene også testet med og uten de nye funksjonene «*heart_score*» og «*lung_score*», som var konstruert fra eksisterende variabler. Denne tilnærmingen gjorde det mulig å vurdere effekten av disse nye funksjonene på modellens ytelse. Ved å sammenligne resultatene fra modellene med og uten disse variablene, fikk man innsikt i hvorvidt de tilførte funksjonene faktisk bidro til å forbedre modellens prediksjonsevne.

Spesielt i delkapitlene «Resultater og Evaluering» vil følgende begreper bli brukt. Her er en forklaring som viser hva hvert begrep refererer til:

- **Originalt datasett:** Dette datasettet inneholder alle tilgjengelige variabler.
- **Redusert datasett:** Dette datasettet inkluderer alle variabler, unntatt «*fysiologisk_score*», «*lege_overlevelsesestimat_6mnd*», og «*overlevelsesestimat_6mnd*» (se avsnittet om "variabelutvelgelse").
- **Datasett med nye funksjoner:** Dette datasettet inkluderer «*heart_score*» og «*lung_score*» (se avsnittet om "variabelutvinning"). I dette tilfellet er «*hjerterefrekvens*», «*blodtrykk*», «*respirasjonsfrekvens*», og «*lungefunksjon_kode*» fjernet fra datasettet.

Dummy Modell

Bruken av en dummy-modell som en baseline i modellering er en viktig praksis for å evaluere ytelsen til mer avanserte modeller. En dummy-modell kan være en enkel modell som forutsier gjennomsnittet av målvariabelen eller gir tilfeldige prediksjoner. I dette prosjektet ga dummy-modellen en validerings-RMSE på 19,65, noe som fungerte som et referansepunkt for å vurdere de neste modellene.

Denne RMSE-verdien indikerte at den gjennomsnittlige prediksjonen av oppholdsdager avvok med 19,65 dager fra de faktiske verdiene. Denne baselen gjorde det lettere å vurdere om de mer komplekse modellene faktisk tilførte verdi. Enhver modell som presterte bedre enn denne RMSE-verdien, ble ansett for å ha en reell forbedring.

Denne sammenligningen var essensiell for å identifisere om modellene fanget opp relevante mønstre i dataene eller bare tilpasset seg tilfeldige variasjoner. Gjennom å ha en klar baseline kunne prosjektet evaluere hvorvidt de valgte modellene forbedret prediksjonen betydelig i forhold til det enkle referansepunktet som dummy-modellen representerte.

Decision Tree Regressor

Modellbeskrivelse

Decision Tree Regressor fungerer ved å strukturere data i et beslutningstre, der hver node i treet representerer en betingelse eller deling basert på en av de uavhengige variablene. Prosessen begynner med å analysere hele datasettet og identifisere den beste variabelen for å dele opp dataene. Dette gjøres ved å evaluere ulike kriterier, som for eksempel reduksjon av varians eller forbedring av prediksjonens nøyaktighet.

Etter den første delingen, vil beslutningstreet kontinuerlig dele opp de resulterende undergruppene i mindre enheter inntil en stoppbetingelse er oppfylt. Slike betingelser kan inkludere maksimal dybde av treet eller når ytterligere delinger ikke gir signifikante forbedringer. Den endelige prediksjonen for et gitt datapunkt lages ved å navigere fra roten av treet til en sluttnode, der verdien representerer gjennomsnittet av målvariabelen for dataene som havnet i den noden.

Forventninger til ytelse

For å forstå den forventede prestasjonen til Decision Tree Regressor, er det nødvendig å vurdere både styrker og svakheter. Beslutningstrær har evnen til å håndtere ikke-lineære relasjoner i dataene uten behov for kompliserte datatransformasjoner. Denne egenskapen gjør dem allsidige og i stand til å tilpasse seg komplekse mønstre. En annen fordel er at beslutningstrær ikke krever normalisering eller standardisering av data.

Til tross for disse fordelene, har beslutningstrær også noen betydelige svakheter. En av de mest kritiske utfordringene er overfitting. Dype trær har en tendens til å overtilpasse treningsdataene, noe som kan føre til dårlig generalisering til nye, usette data. Dette skjer ofte når modellen lærer støyen i treningsdataene i stedet for å identifisere de underliggende mønstrene.

Instabilitet er en annen svakhet ved beslutningstrær. De kan være svært sensitive for små endringer i dataene, noe som innebærer at en liten variasjon kan føre til helt forskjellige trær. Dette kan gjøre modellen mindre robust og vanskeligere å stole på. Videre kan beslutningstrær ha en tendens til å være biased mot dominerende klasser i situasjoner med ubalanserte data. Dette kan resultere i at modellen favoriserer den dominerende klassen, noe som svekker ytelsen for de mindre klassene.

Generelt sett kan beslutningstrær gi solide resultater, spesielt når dataene inneholder komplekse, ikke-lineære relasjoner. Noe som ikke er urealistisk å anta at eksisterer i datasettet når det bygger på flere titalls ulike variabler. Det er altså forventet at modellen vil prestere en god del bedre enn dummy modellen, men ikke like godt som Gradient Boosting Regressor, som kombinerer flere trær for å gi større robusthet til modellen. Relativt sett vil

det være realistisk å forvente at ytelsen til Decision Tree Regressor vil ligge et sted imellom Lasso og Gradient Boosting.

Hyperparametere

Under modelltreningen tunes hyperparametrene: *max_depth*, *min_samples_split*, *min_samples_leaf*, *max_features* og *criterion*.

- **max_depth:** Refererer til den maksimale dybden på beslutningstreet. Å begrense dybden kan redusere risikoen for overfitting, ettersom et dypt tre kan tilpasse seg støy og spesifikke mønstre i treningsdataene som ikke er representative for den generelle befolkningen. En lavere dybde kan føre til en mer robust modell, men det må balanseres, da for lav dybde kan hindre modellen i å fange underliggende mønstre.
- **min_samples_split:** Angir det minste antallet prøver som kreves for å dele en node. Høyere verdier kan hindre modellen i å lage splittinger basert på svært få datapunkter, noe som er avgjørende for å opprettholde en generaliserbar modell. En høyere verdi gjør treet mer konservativt i sin tilnærming til splitting.
- **min_samples_leaf:** Spesifiserer minimum antall prøver som må være til stede i en bladnode. Økning av denne verdien forhindrer opprettelse av noder med for få datapunkter, noe som gir en mer stabil og generaliserbar modell, spesielt nyttig ved støy eller lite variasjon i dataene.
- **max_features:** Kontrollerer antall funksjoner som vurderes ved hver splitting. Ved å begrense antallet tilgjengelige funksjoner kan man redusere kompleksiteten i modellen og motvirke overfitting. Dette tvinger modellen til å fokusere på de mest informative variablene.
- **Criterion:** Bestemmer hvordan kvaliteten på splitting vurderes, med tilgjengelige alternativer som 'squared_error', 'absolute_error', og 'friedman_mse'. Valget av kriterium påvirker hvordan treet lærer fra dataene, og ulike kriterier kan resultere i forskjellige splittingstrategier.

Resultater og Evaluering

Resultatene for Decision Tree-regresjonsmodellen var som følger:

For originalt datasett:

- RMSE med original data: 18.45

- RMSE med outliers fjernet fra treningsdata: 18.45

For det reduserte datasettet:

- RMSE med redusert data: 18.48
- RMSE med outliers fjernet fra treningsdata: 18.48

For datasettet med nye funksjoner:

- RMSE med nye funksjoner: 18.45
- RMSE med outliers fjernet fra treningsdata: 18.45

For Decision Tree Regressor hadde det originale datasettet en RMSE på 18.45, og denne verdien forble uendret etter at outliers ble fjernet. Dette antyder at modellen er robust mot uteliggere, og at tilstedeværelsen av disse ikke har noen signifikant innvirkning på modellens ytelse i dette datasettet.

Ved bruk av det reduserte datasettet ble RMSE målt til 18.48, som heller ikke endret seg ved fjerning av uteliggere. Denne stabiliteten indikerer at reduksjonen i variabelsettet ikke forbedret modellens prediksjonsnøyaktighet, og at de gjenværende variablene fortsatt inneholder nødvendige mønstre for å opprettholde ytelsen.

For datasettet med nye funksjoner ble det observert en RMSE på 18.45 både med og uten uteliggere, noe som tilsvarer ytelsen i det originale datasettet. Resultatet antyder at verken de nye variablene «*heart_score*» og «*lung_score*», eller fjerningen av de opprinnelige variablene, påvirket modellens ytelse. Den uendrede RMSE indikerer at de nye funksjonene og de fjernede variablene ikke bidrar til å forbedre eller svekke modellens evne til å predikere oppholdsdager.

Samlet sett viser analysen at ytelsen til Decision Tree Regressor er stabil på tvers av datasettene, med liten eller ingen påvirkning fra uteliggere. Den beste RMSE oppnådd var 18.45, som representerer en forbedring sammenlignet med en enkel dummy-modell som har en RMSE på 19.65. Selv om 18.45 er en bedre ytelse enn dummy-modellen, innebærer en gjennomsnittlig feil på 18.45 dager en betydelig avstand fra faktiske oppholdstider og viser at modellen har begrensninger i nøyaktighet for presisjonsnivået som ideelt sett kreves for prediksjoner av sykehusopphold.

Lasso

Modellbeskrivelse

Lasso Regressor (Least Absolute Shrinkage and Selection Operator) fungerer ved å utføre lineær regresjon med en straffefunksjon som reduserer koeffisientene til variablene. Denne metoden bruker en L1-norm i kostnadsfunksjonen, som innebærer at den minimerer

summen av de absolutte verdiene til koeffisientene. Formålet med Lasso er å balansere modellens nøyaktighet med kompleksiteten, ved å redusere overflødige variabler og dermed hindre overtilpasning.

I prosessen starter Lasso med en lineær modell som inneholder alle tilgjengelige variabler. Under treningen vil metoden gradvis justere koeffisientene, og etter hvert som straffefunksjonen brukes, kan enkelte koeffisienter reduseres til null. Ved å sette variabler med ubetydelige effekter til null, vil Lasso eliminere dem fra modellen, noe som resulterer i en enklere og mer tolkbar modell med færre funksjoner. Dette gjør Lasso egnet for modellering av datasett med mange variabler og mulige korrelasjoner, da modellen blir enklere uten å miste for mye prediksjonsevne.

Forventninger til ytelse

For å forstå den forventede ytelsen til Lasso Regressor, må vi se på både styrker og begrensninger. Lasso er spesielt egnet for datasett der flere variabler kan ha svakere eller overlappende effekter, siden metoden kan sette koeffisientene til slike variabler til null, noe som eliminerer dem fra modellen. Dette er nyttig når man ønsker en modell som kun inkluderer de mest innflytelsesrike variablene, og kan redusere risikoen for overtilpasning.

Lasso har imidlertid begrensninger når det gjelder å håndtere komplekse, ikke-lineære relasjoner. Siden Lasso baserer seg på en lineær modellstruktur, kan den ha vanskeligheter med å fange opp sammenhenger mellom variabler som ikke følger en lineær trend. Modellen kan derfor bli for enkel til å gi nøyaktige prediksjoner når datasettet inneholder sterke, ikke-lineære mønstre, som kan forekomme i komplekse, medisinske datasett.

Sammenlignet med Decision Tree Regressor og Gradient Boosting Regressor er det forventet at Lasso vil ha noe svakere prediksjonsevne, spesielt fordi det lineære aspektet gjør modellen mindre fleksibel til å tilpasse seg ikke-lineære forhold. Dette kan føre til at Lasso underpresterer i forhold til Decision Tree Regressor, som bedre håndterer slike sammenhenger, og Gradient Boosting Regressor, som kombinerer flere trær for å oppnå høy nøyaktighet og robusthet. Samlet sett kan vi anta at Lasso vil prestere dårligere enn både Decision Tree og Gradient Boosting Regressor, selv om den kan ha en fordel i situasjoner hvor kun de sterkeste variablene ønskes med.

Hyperparametere

Under treningen av Lasso Regressor er hyperparameteren *alpha* sentral i å kontrollere modellens ytelse og kompleksitet. Siden Lasso utfører regulering ved å legge til en straff for store koeffisientverdier, styrer *alpha*-verdien graden av denne straffen.

- **alpha:** Denne hyperparameteren kontrollerer styrken på reguleringen. Ved å justere alpha-verdien, kan man balansere mellom modellens tilpasningsevne og kompleksitet. En høyere alpha-verdi øker straffen for store koeffisienter, som kan redusere risikoen for overfitting, da modellen blir mindre tilbøyelig til å tilpasse seg støy i treningsdataene. En lavere alpha kan på sin side føre til en modell som passer dataene bedre, men risikoen for overfitting kan øke, spesielt i tilfeller med mange prediktorer. Hovedmålet med Lasso er å sette koeffisientene til mindre viktige variabler til null når alpha er høyt nok, noe som effektivt fjerner dem fra modellen og gjør den enklere og mer tolkningsbar.
- **max_iter:** Denne hyperparameteren angir det maksimale antallet iterasjoner for algoritmen som brukes til å tilpasse Lasso-modellen. Hvis modellen ikke har konverget innen dette antallet iterasjoner, stopper treningen. Ved å øke max_iter, kan man sikre at modellen konvergerer, men det kan også føre til økt treningstid, spesielt for store datasett.
- **tol:** Toleransen for konvergens. Når endringen i koeffisientene mellom iterasjoner er mindre enn tol, anses modellen som konverget og treningen avsluttes. En lavere tol kan føre til høyere nøyaktighet, men det kan også øke treningstiden, da modellen vil fortsette å iterere til endringene er svært små.

Resultater og Evaluering

Resultatene for Lasso-regresjonsmodellen var som følger:

For originalt datasett:

- RMSE med original data: 18.17
- RMSE med outliers fjernet fra treningsdata: 18.16

For det reduserte datasettet:

- RMSE med redusert data: 18.46
- RMSE med outliers fjernet fra treningsdata: 18.48

For datasettet med nye funksjoner:

- RMSE med nye funksjoner: 18.18
- RMSE med outliers fjernet fra treningsdata: 18.18

For det originale datasettet viste Lasso-regresjonen en RMSE på 18.17, mens fjerning av outliers fra treningsdataen ga en marginalt bedre RMSE på 18.16. Den lille forbedringen kan indikere at utelatte verdier inneholdt støy som påvirket modellens prediksjoner, men at den

generelle ytelsen fortsatt var ganske lik. Men en så liten forbedring kan også være ren tilfeldighet.

I det reduserte datasettet økte RMSE til 18.46, og ble ytterligere dårligere til 18.48 når utelatte verdier ble fjernet. Denne økningen kan skyldes at fjerning av variabler fra datasettet reduserte modellens evne til å fange opp relevante mønstre, noe som resulterte i dårligere prediksjoner.

For datasettet med nye funksjoner, som inkluderte «*heart_score*» og «*lung_score*», var RMSE på 18.18. Dette tyder på at de nye funksjonene tilførte tilstrekkelig informasjon til å opprettholde modellens ytelse, men at det originale datasettet fortsatt var marginalt bedre.

Til sammenligning viser det seg at Lasso-regresjonsmodellen presterer bedre enn Decision Tree-modellen, som hadde en beste RMSE på 18.45 i motsetning til Lasso sin beste RMSE på 18.16. Dette tyder på at Lasso-modellen gir mer nøyaktige prediksjoner enn Decision Tree, noe som ikke samsvarer med forventningene til Lasso sin ytelse.

En mulig forklaring på denne ytelsen kan være at Lasso-regresjonen, med sin innebygde straff for komplekse modeller fremmer en mer robust modell. I kontrast til Decision Tree, som er bedre i stand til å fange opp ikke-lineære relasjoner i dataene, kan straffen fra Lasso-regresjonen være tilstrekkelig til å kompensere for tapet av informativitet fra de ekskluderte variablene. Dette kan også indikere at Lasso er i stand til å identifisere de mest relevante variablene og eliminere støy fra dataene mer effektivt enn Decision Tree.

Lasso-regresjonsmodellen har vist seg å være en bedre kandidat i denne analysen, med evne til å oppnå lavere RMSE-verdier enn både Decision Tree og Dummy-modellen.

Gradient Boosting Regressor

Modellbeskrivelse

Gradient Boosting Regressor er en regresjonsmodell som kombinerer flere beslutningstrær for å lage en sterkere, mer nøyaktig modell. Denne metoden fungerer ved å bygge trær sekvensielt, der hvert nytt tre forsøker å korrigere feilene fra det forrige treet. Dette oppnås ved å minimere en tapsfunksjon som måler forskjellen mellom de faktiske og predikerte verdiene.

I prosessen begynner Gradient Boosting med en initial prediksjon, som vanligvis er gjennomsnittet av målvariabelen. Deretter beregnes feilene fra denne prediksjonen. Hvert nye tre bygges ved å forsøke å forutsi disse feilene, noe som gjør at modellen gradvis forbedrer seg over tid. Denne iterasjonseffekten gjør at Gradient Boosting kan tilpasse seg

komplekse mønstre i dataene. Enkelt forklart kan man se på Gradient Boosting som en iterativ form for Decision Tree Regression.

Forventninger til ytelse

For å forstå den forventede ytelsen til Gradient Boosting Regressor, er det viktig å se på både styrkene og begrensningene ved metoden. Gradient Boosting bygger på ideen om å kombinere flere beslutningstrær. Ved å trene trærne sekvensielt, der hvert tre korrigerer feilene fra det forrige, kan Gradient Boosting effektivt fange opp både lineære og ikke-lineære relasjoner i dataene. Dette gjør den spesielt kraftig i komplekse datasett.

En av styrkene ved Gradient Boosting er dens evne til å håndtere interaksjoner mellom variabler. Ved å tilpasse seg de ulike mønstrene i dataene kan modellen lære mer om de komplekse forholdene som eksisterer, noe som gir mer nøyaktige prediksjoner. I tillegg kan metoden reguleres ved hjelp av hyperparametere, som læringsrate og antall trær, for å optimalisere ytelsen og redusere risikoen for overtilpasning.

Imidlertid har Gradient Boosting også sine begrensninger. Modellen kan være følsom for støy i dataene, noe som kan føre til overtilpasning dersom ikke tilstrekkelig regulering blir brukt. I tillegg kan treningstiden være lengre sammenlignet med enklere modeller, ettersom den krever sekvensiell læring fra flere trær.

Når man sammenligner Gradient Boosting med Lasso og Decision Tree Regressor, er forventningen at Gradient Boosting vil prestere bedre enn begge. Dette skyldes dens evne til å kombinere styrkene til flere trær, noe som gir den robusthet og høy nøyaktighet. I motsetning til Lasso, som kan ha vanskeligheter med å fange opp komplekse, ikke-lineære relasjoner på grunn av sin lineære natur, og Decision Tree, som kan overtilpasse seg datasett med høy variabilitet, gir Gradient Boosting en mer stabil tilnærming.

Hyperparametere

Hyperparameterene *max_depth*, *min_samples_split*, og *min_samples_leaf*, blir som i likhet med Decision Tree Regressor også brukt her. For en forklaring på disse parameterne samt hvordan de påvirker trestrukturen og modellens generelle ytelse se «Decision Tree Regressor, hyperparametere». Her er en forklaring på de resterende hyperparametere som blir brukt for Gradient Boosting Regressor:

- **n_estimators:** Dette parameteret angir antall beslutningstrær (estimators) som skal bygges i modellen. Hver estimator lærer av feilene fra de foregående trærne, noe som bidrar til å forbedre modellens ytelse. For mange trær kan føre til overtilpasning, mens for få trær kan resultere i undertilpasning.

- **learning_rate:** Læringsraten bestemmer hvor mye hver estimator bidrar til den endelige modellen. En lav læringsrate (f.eks. 0.01) vil føre til en mer forsiktig tilnærming, hvor hver estimator kun påvirker modellens prediksjoner i liten grad. Dette kan føre til bedre generalisering, men vil kreve flere estimators for å oppnå samme ytelse. Høyere verdier (f.eks. 0.1, 0.2) gir raskere læring, men kan føre til overtilpasning.
- **subsample:** Subsample parameteren angir andelen av treningsdataene som skal brukes til å trene hvert enkelt tre. Bruk av et delsett av dataene kan bidra til å øke variasjonen og redusere overtilpasning. En subsample-verdi på 0.8 betyr at 80 % av dataene brukes for hver estimator, mens 1.0 betyr at hele datasettet brukes. Dette kan påvirke modellens robusthet og generaliseringsevne.

Resultater og Evaluering

Resultatene for Gradient Boosting-regresjonsmodellen var som følger:

For originalt datasett:

- RMSE med original data: 17.83
- RMSE med outliers fjernet fra treningsdata: 17.59

For det reduserte datasettet:

- RMSE med redusert data: 18.27
- RMSE med outliers fjernet fra treningsdata: 18.11

For datasettet med nye funksjoner:

- RMSE med nye funksjoner: 17.76
- RMSE med outliers fjernet fra treningsdata: 17.78

For det originale datasettet viste Gradient Boosting en RMSE på 17.83, mens fjerning av outliers fra treningsdataene ga en forbedring med en RMSE på 17.59. Denne forbedringen indikerer at utelatte verdier inneholdt støy som påvirket modellens prediksjoner, og at Gradient Boosting, med sin evne til å lære av residualene til tidligere trær, klarer å håndtere slike uregelmessigheter bedre enn enklere modeller.

I det reduserte datasettet økte RMSE til 18.27, men ble noe bedre til 18.11 når outliers ble fjernet. Denne økningen kan skyldes at fjerning av variabler fra datasettet reduserte modellens evne til å fange opp relevante mønstre. Gradient Boosting kan, som Lasso, lide av

informasjonstap når disse variablene ble eliminert, men viser likevel en mer robust ytelse enn Lasso i dette tilfellet.

For datasettet med nye funksjoner hadde Gradient Boosting en RMSE på 17.76, som indikerer at de nye variablene tilfører nyttig informasjon. Interessant nok, da outliers ble fjernet, økte RMSE til 17.78. Dette kan antyde at de nye funksjonene bidro til en bedre tilpasning, men at fjerning av utelatte verdier førte til tap av kritiske datapunkter.

Sammenlignet med Lasso og Decision Tree, presterte Gradient Boosting konsekvent bedre. Lasso hadde en beste RMSE på 18.16, mens Decision Tree-modellen fikk en RMSE på 18.45. Gradient Boosting overgikk disse resultatene, noe som tydeliggjør modellens styrke i å håndtere komplekse og ikke-lineære relasjoner i dataene. Forventningene stemte dermed overens; Gradient Boosting viser seg å være bedre enn både Decision Tree og Lasso i denne analysen.

Endelig modell

Ved evalueringen av de tre modellene med ulike variasjoner i datasettet, ble det observert at Gradient Boosting-modellen, trent på det originale datasettet med uteliggere fjernet fra treningsdataene, oppnådde den laveste validerings-RMSE på 17,59.


Figur 5 presenterer modellen sammen med de aktuelle hyperparameterne. Det er spesielt bemerkelsesverdig at verdien for *subsample* er satt til 0,8. Dette

innebærer at modellen bruker 80% av treningsdataene til å trene hvert enkelt beslutningstre, istedenfor 100%. Årsaken er nok at denne tilnærmingen bidrar til å redusere risikoen for overfitting ved å gi et variert utvalg av data for hver iterasjon, samtidig som den fremdeles drar nytte av et stort datagrunnlag for å lære. Dette kan forbedre modellens generaliseringsevne, da den lærer fra forskjellige subset av dataene i hver treningsrunde.

Videre ble ulike polynomialgrader testet på modellen for å identifisere hvilken grad som ga den laveste RMSE. Resultatene viste at polynomgrad 1 (lineær) ga de beste prediksjonene, noe som indikerer at en lineær tilnærming var tilstrekkelig for å fange opp de underliggende mønstrene i datasettet.

De Mest Sentrale Variablene

Figur 7 viser feature importances for den endelige modellen, noe som gir innsikt i hvilke variabler som har størst betydning for prediksjonene. Den mest fremtredende variabelen er «sykdom underkategori ARF/MOSF w/Sepsis», som har en *importance*-verdi på opp i mot 0.25. Dette signaliserer at pasienter med akutt respiratorisk svikt eller multiorgansvikt



```
GradientBoostingRegressor(min_samples_leaf=4, min_samples_split=5,
                           n_estimators=300, n_iter_no_change=10,
                           random_state=42, subsample=0.8)
```


Figur 6: Endelig modell med optimaliserte hyperparametere.

kombinert med sepsis er spesielt risikoutsatt, noe som kan ha stor betydning for oppholdslengde.

Videre er overlevelsesestimatene for henholdsvis 6 måneder (ca. 0.063) og 2 måneder (ca. 0.054) blant de nest mest betydningsfulle variablene. Dette er signifikant lavere enn «sykdom_underkategori_ARF/MOSF w/Sepsis», men likevel av stor betydning for modellen. Dette indikerer at informasjon om pasientens langsiktige prognose er avgjørende for å forutsi utfallet av sykehusoppholdet.

Alder, med en *importance*-verdi på rundt 0.059, viser også betydelig innflytelse på modellen. Dette er i samsvar med eksisterende forventning som antyder at eldre pasienter ofte har høyere risiko for komplikasjoner og dårligere prognoser. I tillegg viser flere kliniske indikatorer, som «*apache_fysiologisk_score*», «*glukose*» og «*blodtrykk*», seg å være viktige for modellens prediksjoner.

Det er imidlertid også viktig å merke seg at flere variabler, som «*inntekt_kode*» og «*sykdom_underkategori_CHF*», har en *importance*-verdi på 0. Dette indikerer at disse variablene ikke bidrar til modellens evne til å forutsi utfallet. En videre vurdering av disse variablene kan føre til beslutninger om fjerning fra datasettet, ettersom de kan skape unødvendig kompleksitet uten å tilføre særlig relevant informasjon.



Figur 7: Viser feature importances for den endelige modellen, der variablene er rangert etter deres innflytelse på prediksjonene. De høyeste verdiene indikerer størst betydning, dette gir innsikt i hvilke faktorer som mest påvirker oppholdslengden.

Test - RMSE

Til slutt ble det regnet ut test-RMSE for å få et objektivt resultat som vurderte modellens generaliseringsevne på usett data. Test-RMSE ble beregnet til 16.57, noe som gir en indikasjon på hvordan modellen presterte når den ble konfrontert med data den ikke hadde sett tidligere.

Ved sammenligning av test-RMSE med den tidligere validerings-RMSE på 17.59, er det verdt å merke seg at test-RMSE er lavere enn validerings-RMSE. Dette kan tyde på at modellen var i stand til å tilpasse seg testdatasettet bedre enn valideringsdatasettet. En mulig årsak til at test-RMSE var lavere, kan være at testdatasettet inneholdt mindre støy eller representerte et mindre variert spekter av data sammenlignet med valideringsdatasettet.

Det er imidlertid viktig å nevne at en modell for predikering av oppholdslengde med en RMSE på 16.57 fortsatt blir ansett som ganske høy, og modellen har derfor begrenset praktisk verdi i kliniske settinger. I det siste underkapittelet blir potensielle alternative tilnærminger og tiltak som kunne forbedret prediksjonen drøftet.

Modellens Prediksjonsevne: Styrker og Begrensninger

Analysen av modellens prediksjoner avdekker betydelige forskjeller i ytelsen avhengig av lengden på oppholdene. Modellen klarte godt å predikere oppholdslengder nært medianen for treningssettet, som var 11 dager. Når man vurderer medianverdiene for prediksjoner på testsettet der modellen avvike med tre dager eller mindre, fremstår resultatene svært lovende. For eksempel, da den faktiske oppholdslengden var 12 dager, predikerte modellen en lengde på 11.87 dager, noe som resulterte i en liten feilmargin på kun 0.73 dager. Dette indikerer at modellen har en god generaliseringsevne for typiske opphold.

Imidlertid er situasjonen veldig annerledes når det gjelder lange opphold. For observasjoner der modellen feiler med mer enn 30 dager, er medianen for faktisk oppholdslengde 69 dager, mens den predikerte lengden er bare 23.85 dager, noe som resulterer i en betydelig negativ medianfeil på -45.15 dager. Dette sterke negative avviket indikerer at modellen konsekvent undervurderer lengden på oppholdene for disse tilfellene.

Det er flere faktorer som kan forklare denne svikten i prediksjonene for lange opphold. For det første kan treningsdataene ha inneholdt for få observasjoner med lange opphold, noe som gjør at modellen ikke har tilstrekkelig informasjon til å lære fra disse tilfellene. Det kan også være at lange opphold påvirkes av en rekke komplekse faktorer som ikke er godt fanget opp i modellen, noe som bidrar til usikkerhet og feil. Tidligere analyser, som boksplottet av oppholdslengde (figur 1), viste også stor variasjon av store oppholdslengder utenfor whiskers, noe som antyder at ekstreme verdier er mer atypiske og vanskeligere å forutsi.

Samlet sett viser analysen at modellen er effektiv for vanlige opphold, men utilstrekkelig for lange opphold. Den store negative medianfeilen i de lange oppholdene fremhever et behov for alternative tilnærminger for å forbedre prediksjonene, spesielt for pasienter med lengre opphold. Her kunne det vært fordelaktig å vurdere segmentering av dataene, samt implementere spesialiserte modeller for å håndtere variasjonen og kompleksiteten i denne pasientpopulasjonen. Dette er drøftet mer i underkapittelet nedenfor.

Drøfting av Andre Modelltilnærminger

Lineær regresjon ble prøvd som en mulig modell. Denne modellen opplevde imidlertid utfordringer, da prediksjonene ofte resulterte i negative verdier. En av hovedårsakene til dette kan være at lineær regresjon antar en lineær sammenheng mellom de uavhengige og avhengige variablene. I denne konteksten, hvor oppholdslengde nødvendigvis må være en positiv verdi, var det ikke tilstrekkelig for modellen å kun lære av lineære relasjoner. Den klarte derfor ikke å konvergere mot en løsning som holdt seg innenfor det positive området, noe som gjorde lineær regresjon til en dårlig kandidat.

En alternativ tilnærming som ble vurdert, var segmentering av pasientdataene gjennom en klassifiseringsmodell. I denne modellen ville pasientene først bli kategorisert i grupper basert på forventet oppholdslengde: kort, moderat eller langt opphold. Deretter ville spesifikke regresjonsmodeller bli trent for hver kategori. Denne tilnærmingen kunne ha flere fordeler. For det første ville segmenteringen kunne redusere variasjonen innen hver spesifikke regresjonsmodell, noe som potensielt kunne gi mer presise resultater. Ved å fokusere på spesifikke grupper kunne modellene bedre tilpasse seg unike mønstre og egenskaper i dataene for hver kategori.

Likevel ble denne tilnærmingen forkastet etter grundig vurdering. En av de viktigste ulemper var kompleksiteten som oppsto fra behovet for å bruke to modeller: først en klassifiseringsmodell etterfulgt av en regresjonsmodell. Denne dobbelte prosessen kan introdusere ytterligere usikkerhet og større prediksjonsfeil, da feil i klassifiseringstrinnet ville påvirke resultatene fra regresjonsmodellen. Den økte kompleksiteten kunne dermed undergrave fordelene ved mer presise resultater i de spesialiserte modellene.